基于节点信号的动态图边权概率递推估计

Gurui Jin and Ercan E. Kuruoğlu

摘要—动态图跟踪需要同时估计边是否存在及其作用强度。本文研究一种从节点信号估计动态图边权的概率递推方法：依据节点动态构造边权回归，通过马尔可夫预测和均值场更新维护每条边的概率，再由支持判定及正幅度估计构造拉普拉斯矩阵，输出完整图谱。在 24 条合成条件轨迹、1,728 个时间块上，相比已有稀疏 EKF 代码的硬阈值适配，边权和特征值平均相对误差分别由 0.15134 和 0.08741 降至 0.12163 和 0.06527，真实连通块的误分裂由 76/1068 降至 8/1068。该估计质量改善伴随更高计算成本及更大的事件块增量误差。本文以同一方法的结构、权重和谱输出检验这一取舍。

***Index Terms*—动态图学习，边权估计，概率递推，均值场近似，图谱。**

I. 引言

图信号处理用图描述节点间的相互作用，并用拉普拉斯谱刻画信号变化模式 [1]。当连接会消失、恢复且强度持续变化时，在线估计既要跟踪非零幅度，也要区分弱连接和不存在的连接。本文研究的问题是：在已知节点相互作用模型下，如何从连续观测的节点信号递推估计这些边，并得到与估计图一致的 U_t, Λ_t？

Natali 等人研究在线图学习的时变优化 [2]；Dabush 等人以边权为隐状态、图滤波信号为观测，提出稀疏 EKF [3]。图拉普拉斯的边权参数化及一阶图滤波的线性特例属于已有研究基础。本文采用的均值场坐标更新也基于标准变分推断 [4]。

本文的中心设计是从节点状态的连续观测构造边权似然，递推维护每条边的离散概率分布，再由该分布估计连接及其强度。方法由马尔可夫预测、均值场更新和点估计读出组成。用分布而非单个数值传递上一时间块的信息，是本文估计器的表示方式。实验评价这套估计器相对于文献来源基线的误差、结构识别和计算成本。

Gurui Jin and Ercan E. Kuruoğlu are with Shenzhen International Graduate School, Tsinghua University, Shenzhen, China (e-mail: jgr23@mails.tsinghua.edu.cn; kuruoglu@sz.tsinghua.edu.cn).

II. 节点观测如何提供边权信息

A. 未知量、观测与模型依据

n 个节点上的标量信号为 $s_{t,k} \in \mathbb{R}^n$。t 表示图更新的时间块，k 表示块内采样。未知量 $\theta_t \in [0,1]^m$ 是 m 条候选边的权重，不是节点值。令关联矩阵 $B = [b_1, \ldots, b_m]$，每列在一条边的两端分别取 $+1, -1$，其余为零，则

$$L(\theta_t) = B \operatorname{diag}(\theta_t) B^{\mathsf{T}}. \tag{1}$$

方向仅用于记号，反转 b_e 不会改变 $b_e b_e^{\mathsf{T}}$。

本文采用一阶局部相互作用模型

$$s_{t,k+1} = (aI - \eta L(\theta_t)) s_{t,k} + u_{t,k} + \epsilon_{t,k}. \tag{2}$$

其节点形式是 $s_{i,k+1} = a s_{i,k} + u_{i,k} - \eta \sum_j \theta_{ij}(s_{i,k} - s_{j,k}) + \epsilon_{i,k}$：自身演化与已知输入之外，邻居通过信号差产生作用。这是离散扩散型图滤波 [1]，适用于信号满足这种交互规律的系统。实验同步观测全部 s，已知 a, η, u, σ；过程扰动 $\epsilon \sim \mathcal{N}(0, \sigma^2 I)$ 在各次转移间独立，且独立于当前状态。没有额外传感器测量误差。

可用房间换热作类比：节点信号是各房间温度，边权表示房间间的换热强度，$as + u$ 给出暂不计房间间换热时的下一步温度。实际温度与此预测的差异包含房间之间的作用及扰动。因此，多次温度变化提供关于换热强度的信息。

B. 残差的意义与逐步推导

定义由实际观测计算的残差

$$r_{t,k} = a s_{t,k} + u_{t,k} - s_{t,k+1}. \tag{3}$$

式(3)中，$s_{t,k}$ 是当前观测的节点信号向量；a 是已知自身演化系数，$as_{t,k}$ 表示仅考虑自身演化的下一步预测；$u_{t,k}$ 是这一采样间隔内的已知外部输入；$s_{t,k+1}$ 是下一时刻实际观测。先将前两项相加得到忽略邻居作用的预测，再减去实际观测，得到 $r_{t,k}$。例如单个节点的当前值为 1、$a=0.9$、输入为 0.02、下一观测为 0.82，则残差为 $0.9\times1+0.02-0.82=0.10$。这个差值包含邻居耦合作用及扰动。为简洁省略 t,k，代入式(2)得

$$\begin{aligned} r &= as+u-[(aI-\eta L)s+u+\epsilon] \\ &= \eta L s-\epsilon \\ &= \eta B\,\mathrm{diag}(\theta)B^{\mathsf T}s-\epsilon \\ &= \underbrace{\eta B\,\mathrm{diag}(B^{\mathsf T}s)}_{H}\theta-\epsilon. \end{aligned} \tag{4}$$

最后一步使用逐元素恒等式 $\mathrm{diag}(\theta)d=\mathrm{diag}(d)\theta$，其中 $d=B^{\mathsf T}s$。因此 H 的第 e 列为 $\eta b_e(b_e^{\mathsf T}s)$：端点位置乘以端点信号差，再乘耦合系数。给定已观测的 s 后，H 可计算，式(4)对未知 θ 是线性的。

观测到来前，s_{k+1} 及 r 受随机扰动和未知边权影响；观测到来后，r 的数值可直接计算。这与似然中的随机性并不矛盾。反演边权结合上述观测模型与多次状态转移提供的信息。

C. 三节点例子与块内堆叠

取候选边 $(1,2),(1,3),(2,3)$，$s=(1,0,0.5)^{\mathsf T}$，$a=0.9$、$\eta=0.1$、$u=0$。则

$$B=\begin{bmatrix} 1 & 1 & 0\\ -1 & 0 & 1\\ 0 & -1 & -1 \end{bmatrix},\quad H=\begin{bmatrix} .1 & .05 & 0\\ -.1 & 0 & -.05\\ 0 & -.05 & .05 \end{bmatrix}. \tag{5}$$

例如第二列是 $0.1(1,0,-1)^{\mathsf T}(1-0.5)$。用示意真值 $\theta=(0.8,0.5,0)^{\mathsf T}$、$\epsilon=0$ 正向生成，得到 $H\theta=(.105,-.08,-.025)^{\mathsf T}$ 及 $s_{k+1}=(.795,.08,.475)^{\mathsf T}$。反过来，观测者用 $0.9s-s_{k+1}$ 算得同一个 r，但并不知道生成时的 θ。继续收集块内观测，可得到关于同一组边权的更多方程。

块内保持同一个 θ_t，收集 K 次转移得到 K 组方程。“堆叠”是将这些方程上下排列，而非求平均：

$$\underbrace{\begin{bmatrix} r_{t,0}\\ \vdots\\ r_{t,K-1} \end{bmatrix}}_{r_t\in\mathbb{R}^{nK}} = \underbrace{\begin{bmatrix} H_{t,0}\\ \vdots\\ H_{t,K-1} \end{bmatrix}}_{H_t\in\mathbb{R}^{nK\times m}}\theta_t-\epsilon_t. \tag{6}$$

每增加一次转移，就增加一组关于同一未知边权的约束。若所有端点信号相同，则 $B^{\mathsf T}s=0$、$H=0$，无法从该次变化辨识边权。堆叠后的 H_t 满列秩是无约束无噪声回归唯一解的充分条件；先验无法替代缺失的观测信息。

III. 边权分布的递推估计

A. 有限分布与时间预测

每条边取值 $v_j=j/64, j=0,\dots,64$，以 $q_{t,e}(j)$ 表示其近似概率。其中 $v_0=0$ 表示没有边，$v_j>0$ 表示连接强度。时间递推为

$$p^{-}_{t,e}(j)=\sum_{i=0}^{64} q_{t-1,e}(i)T_{ij}. \tag{7}$$

T_{ij} 表示上一块的权重 v_i 转至当前 v_j 的概率。实验固定零与正状态之间的切换概率均为 0.01/块，正幅度采用离散化高斯转移。第一块直接使用初始分布，其零状态概率为 0.5；后续每块在观测更新前预测一次，块内不重复注入图变化。

B. 为什么使用均值场，以及怎样更新

每条边有 65 个状态，精确联合枚举需要 65^m 个组合；因子化表示 $q_t(\theta_t)=\prod_e q_{t,e}(\theta_{t,e})$ 仅需 $65m$ 个概率。均值场把边间作用通过当前均值传入各边更新，以放弃一般边间相关性的表示换取可计算性 [4]。

对已观测轨迹，各次条件转移密度相乘，关于 θ_t 的对数似然为

$$\begin{aligned} \ell_t(\theta_t) &= -\tfrac{1}{2}\theta_t^{\mathsf T}G_t\theta_t+h_t^{\mathsf T}\theta_t+C, \\ G_t &= H_t^{\mathsf T}H_t/\sigma^2,\quad h_t=H_t^{\mathsf T}r_t/\sigma^2. \end{aligned} \tag{8}$$

这是顺序状态转移的似然；不需要假定完整轨迹形成的设计矩阵与所有过程噪声相互独立。记 $\mu_{t,f}=$

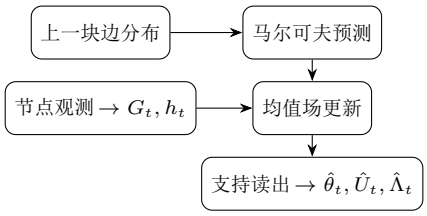


图 1. 所提估计器的预测、观测更新及输出。更新后的边分布传至下一块。

$\sum_j v_j q_{t,f}(j)$，标准均值场规则 $\log q_{t,e} = \log p^-_{t,e} + \mathbb{E}_{-e}\ell_t + \text{const}$ 给出

$$q_{t,e}(j) \propto p^-_{t,e}(j)\exp[-\tfrac{1}{2}G_{t,ee}v_j^2 + c_{t,e}v_j], \qquad c_{t,e} = h_{t,e} - \sum_{f\neq e} G_{t,ef}\mu_{t,f}. \tag{9}$$

对其他边取期望后，交叉项 $-G_{ef}\theta_e\theta_f$ 成为 $-G_{ef}v_j\mu_f$；与 v_j 无关的项由归一化吸收。实现按固定边序逐边归一化更新，最多 30 轮；均值及概率的最大变化均不超过 10^{-8} 时停止。达到上限的结果保留并记录。

C. 一个方法、一套点估计输出

本稿固定采用支持读出：

$$\hat{\theta}_{t,e} = \begin{cases} 0, & q_{t,e}(0) \geq 1/2, \\ \dfrac{\sum_{j=1}^{64} v_j q_{t,e}(j)}{1 - q_{t,e}(0)}, & q_{t,e}(0) < 1/2. \end{cases} \tag{10}$$

该规则先按边存在的概率作二元判定，再估计存在条件下的幅度。例如 $q(0) = 0.7$ 时直接输出零，避免以混合平均值留下小正边。该输出先判定连接是否存在，再估计存在时的强度。

随后由式(1)计算 $\hat{L}_t$，并作完整特征分解 $\hat{L}_t = \hat{U}_t\hat{\Lambda}_t\hat{U}_t^\top$。递推状态是 $q_{t,e}$；每块的 U, Λ 通过完整 EVD 从点估计图计算，作为派生输出用于谱误差评价。它们不参与边权分布更新。

D. 与已有滤波方法的区别

本方法和 KF 共享贝叶斯预测–更新结构，差别在状态分布的表示及更新计算。高斯 KF 用均值和协方差描述连续状态；本方法保留零点质量及正权重网格概率，使用式(9)更新。即便过程噪声是高斯的，零状态与非负幅度组成的边权后验也不必是单个高斯。差别不在于当前观测是否非线性：式(4)是对边权线性的精确恒等式，无需 EKF 泰勒展开。文献 [3] 还处理更一般的非线性图滤波。

Algorithm 1 由节点信号递推估计动态图边权

Require: 节点观测、已知 u, a, η, σ，B, T 及初始边分布

for 每个时间块 t **do**
  首块使用初始分布；其余块按式(7)预测
  由式(3)、(4)构造 r_t, H_t 及 G_t, h_t
  以预测分布初始化 q 并计算各边均值
  for 至多 30 轮，按固定顺序遍历各边 e **do**
    按式(9)计算、归一化 $q_{t,e}$ 并更新均值
    每轮结束检查概率与均值变化；均 $\leq 10^{-8}$ 则停止
  end for
  用式(10)输出 $\hat{\theta}_t$，保存 q_t 供下一块使用
  构造 $\hat{L}_t$；完整 EVD 输出 $\hat{U}_t, \hat{\Lambda}_t$
end for

IV. 实验与已有方法比较

A. 共同任务及指标

使用 6/12 节点、两类结构变化生成器、两种激励条件及每条件 3 次图抽样，共 24 条 72 块合成轨迹；每块 $K = 48$ 次转移。完整候选边数 $m = n(n-1)/2$。参数为 $a = 0.95$、$\eta = 0.8/n$、$\sigma = 0.03$，零均值高斯输入的标准差为 0 或 0.3。图与观测使用预先固定的新种子，估计器参数承接开发阶段；成对激励条件共享图，不将 1,728 块当作独立重复样本。

文献基线。主对照是 Dabush 等人公开代码 [3], [5] 的硬阈值分支，适配到相同回归观测并约束到 $[0, 1]$，阈值 0.1 沿用开发设置；称为“稀疏 EKF 适配”，区别于论文的 ℓ_1 主算法。补充对照 ProbSSM 来自同一作者仓库 [5]，维护逐节点的二值邻边配置概率，正幅度固定为 1，分别采用作者的平均和局部 MAP 读出。它是仓库基线，不是本文提出的另一个方法，也不替代论文主算法。

所有方法只访问相同节点观测及已知参数，并对点估计图计算完整谱。令 λ_t 为升序排列的全部

表 I
相同观测上的图估计结果。误差及误分裂越小越好，正确分区越多越好；各列最优值加粗。

方法	E_θ	E_λ	正确分区	误分裂
所提方法	**.12163**	**.06527**	404/660	8/1068
稀疏 EKF 适配	.15134	.08741	330/660	76/1068
ProbSSM 平均	.16894	.08844	2/660	**0/1068**
ProbSSM 局部 MAP	.19677	.10135	**545/660**	103/1068

特征值，逐块误差为

$$E_\theta(t) = \frac{\|\hat{\theta}_t - \theta_t\|_2}{\max(\|\theta_t\|_2, 10^{-15})}, \qquad E_\lambda(t) = \frac{\|\hat{\lambda}_t - \lambda_t\|_2}{\max(\|\lambda_t\|_2, 10^{-15})}. \tag{11}$$

表中报告全部块的平均值。“正确分区”要求真实断开时估计图的全部连通分量与真值一致；“误分裂”是真实连通时误判为多个分量。二者分别以 660 个断开块和 1068 个连通块为分母，依据点图中严格正边计算。

B. 估计质量、变化误差与代价

相较稀疏 EKF 适配，所提方法平均边权误差降低约 19.6%，特征值误差降低约 25.3%，并改善汇总分区结果。ProbSSM 局部 MAP 恢复了更多断开分区，但也产生更多误分裂；其两种读出共享同一推断。ProbSSM 是在已使用观测上追加的对照，固定正幅度与多值真边权存在失配，参数未独立优化。

对存在真实支持变化的事件块，所有边的点增量误差先平方平均再开方。所提方法为 0.11435，稀疏 EKF 适配为 0.09379；平均估计精度改善并未同时改善突变响应。单线程在线时间包含统计量、推断及完整 EVD，平均为 9.75 和 1.04 秒/轨迹；初始化、预热、存储和评价不计入，机器非独占。所提方法有 14/1728 块达到迭代上限。保留这些块计算全部结果。

在既有共同谱间隔筛选下，5,517 个正单重特征方向的投影误差均值为 0.86552（所提）和 0.87621（稀疏 EKF 适配）。筛选依赖真值及原实验全部输出，不覆盖重根子空间；该诊断不足以建立完整 U 的普遍优势。

表 II
无人机高层合成模型：平均相对误差与每块耗时。

输入标准差	方法	E_θ	E_λ	毫秒/块
0	所提方法	**.33687**	**.11018**	2.92
0	稀疏 EKF 适配	.39423	.15612	**.56**
0.3	所提方法	**.07065**	**.02180**	3.30
0.3	稀疏 EKF 适配	.09069	.03621	**.59**

C. 无人机高度协同的合成实验

考虑 6 架无人机的高层高度协同，令 $s_i = z_i - z_{\mathrm{ref}}$ 为相对 30 米参考高度的偏差。采用一阶高度响应与邻居一致性反馈 [6]，在采样间隔 $\Delta = 0.1$ 秒下，欧拉离散化给出

$$s_{i,k+1} = (1 - \kappa\Delta)s_{i,k} + u_{i,k} + \epsilon_{i,k} - c\Delta \sum_j \theta_{ij}(s_{i,k} - s_{j,k}). \tag{12}$$

取 $\kappa = 0.5$、$c\Delta = 0.8/6$，即式(2)。u_i 是已知高度控制增量，边权是有效邻居反馈强度。水平位置由预设航迹生成，每块保持不变；水平距离 d_{ij} 决定 $\theta_{ij} = \mathbf{1}[d_{ij} < 35]\exp[-(d_{ij}/25)^2]$，距离单位为米。估计器仅接收节点高度序列、输入及已知参数。

固定 6 个新几何种子 720110–720115，每个种子分别使用输入标准差 0 和 0.3，共 12 条 36 块轨迹、432 块，每块 48 次转移。两种估计器沿用原参数。两种输入条件共享几何轨迹，3/432 个所提方法时间块达到迭代上限并保留。全部节点同步可见，采用理想一阶高度响应。表II给出这项合成模型实验的结果。

为考察估计模型在决策中的作用，取每块末端的相同高度状态 s，分别用所提方法、稀疏 EKF、无图模型和真实图模型计算下一步控制。统一最小化预测高度偏差与控制代价之和，得到 $v = \mathrm{clip}(-\hat{F}s/2, -1, 1)$，其中 $\hat{F} = aI - \eta\hat{L}$；无图对照取 aI。在同一真实模型及同一扰动 w 下，评价 $J = \|Fs + v + w\|^2 + \|v\|^2$。输入标准差 0.3 时，四者平均 J 依次为 0.701610、0.701721、0.745394 和 0.701512；所提方法相对无图模型降低 5.87%，与稀疏 EKF 的差距仅 0.016%。输入标准差 0 时，相应数值为 0.011256、0.011258、0.011698 和 0.011236。此处是同状态单步决策回放，各方法的动作不传入

后续观测。$\hat{F} = \hat{U}(aI - \eta\hat{\Lambda})\hat{U}^{\mathsf{T}}$ 与直接使用 $\hat{L}$ 等价；该实验检验估计图的用途。

V. 结论

本文从连续节点观测构造边权回归，利用马尔可夫预测和均值场更新递推维护边权分布，并输出动态连接及其强度。原合成比较中，相对稀疏 EKF 适配，平均边权和特征值误差分别降低 19.6% 和 25.3%，误分裂由 76/1068 降至 8/1068，同时计算成本和事件块增量误差更高。新增高度协同合成实验也呈现较低的平均估计误差；单步控制代价接近稀疏 EKF。结果说明了这套估计器在精度、计算量与动态响应之间的具体取舍。

参考文献

[1] D. I. Shuman, S. K. Narang, P. Frossard, A. Ortega, and P. Vandergheynst, "The emerging field of signal processing on graphs: Extending high-dimensional data analysis to networks and other irregular domains," *IEEE Signal Process. Mag.*, vol. 30, no. 3, pp. 83–98, 2013.

[2] A. Natali, E. Isufi, M. Coutino, and G. Leus, "Learning time-varying graphs from online data," *IEEE Open J. Signal Process.*, 2022, doi: 10.1109/OJSP.2022.3178901.

[3] L. Dabush, N. Shlezinger, and T. Routtenberg, "Sparsity-aware extended Kalman filter for tracking dynamic graphs," arXiv:2507.09999, 2025.

[4] D. M. Blei, A. Kucukelbir, and J. D. McAuliffe, "Variational inference: A review for statisticians," *J. Amer. Statist. Assoc.*, vol. 112, no. 518, pp. 859–877, 2017.

[5] L. Dabush, "PolyEKF," source snapshot cbb1a0a (full commit recorded with the experiments), `baseline_prob_ssm.py` and EKF implementation. [Online]. Available: https://github.com/lital-dgold/PolyEKF

[6] R. Olfati-Saber and R. M. Murray, "Consensus problems in networks of agents with switching topology and time-delays," *IEEE Trans. Autom. Control*, vol. 49, no. 9, pp. 1520–1533, 2004, doi: 10.1109/TAC.2004.834113.